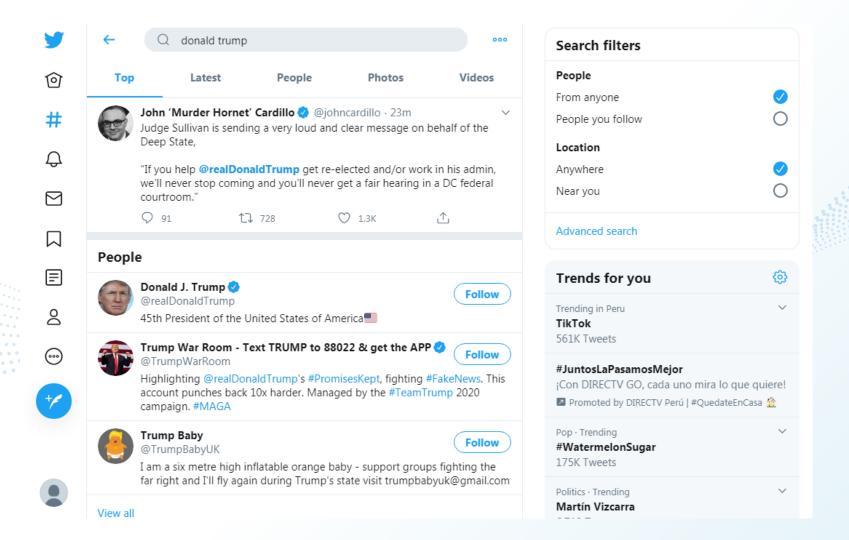
Extracción y análisis de tweets



- Servicio de Microblogging
- Mensajes cortos llamados tweets (máximo de 140 caracteres)
- Cualquiera nos puede seguir y podemos seguir a cualquiera
- Mantener Conversaciones públicas
- Enterados de tópicos de conversación



Cómo acceder a los datos?

- Ingresar y crear una cuenta https://apps.twitter.com/.
- Crear una app
- Obtener los siguientes datos:
 - API Key
 - API secret Key
 - Access token
 - Access token secret

Autenticación

```
import tweepy
from tweepy import OAuthHandler
#Credenciales del Twitter APT
access key = "XXXXXXX"
access secret = "XXXXXXX"
consumer key = "XXXXXXX"
consumer secret = "XXXXXXX"
'''Método de Autenticación para conectarse a twitter'''
def autenticacion():
    auth = tweepy.OAuthHandler(consumer key, consumer secret)
    auth.set access token(access key, access secret)
    api = tweepy.API(auth)
    return api
```

Timeline

'''leer el timeline de nuestra cuenta de Twitter '''

```
def get my tweets():
   api = autenticacion()
   public tweets = api.home timeline(10)
   for tweet in public tweets:
        print (tweet.text)
get my tweets()
                #Opinión21
                Juan José García: De interés nacional
                Lee y comenta 'Opina.21' https://t.co/0Ld1HK3qJl https://t.co/OBHDYmbne9
                Natalia Lafourcade casi lista para lanzar su nuevo disco https://t.co/yIfPyYHKSk
                Raheem Sterling: "Miembros de mi familia murieron por coronavirus"
                https://t.co/JEse4R03iN
               #Día59
                Hombre llena de saliva carrito de supermercado e intenta escupir a un agente de seguridad en
                https://t.co/yReyy2DqQx
               #Día59
               Hombre con síntomas de #COVID_19 muere en puerta del Hospital Angamos https://t.co/EvVyw7f1cc
                VGG7fCT4JH
                Estación Espacial Internacional se pudo ver desde el cielo de Lima
                https://t.co/EkGY2fFxEZ
```

Obtener información de un Usuario

```
'''obtener información de un usuario'''
def get_last_tweets_x_user(screen_name):
                                                          api.get_user: función para obtener
    api = autenticacion()
                                                          información del usuario
    tweetCount = 10
                                                           api.user_timeline: función para obtener los
                                                          tweets del usuario (se indica la cantidad de
    print("Getting data for " + screen_name)
                                                          tweets)
    item = api.get_user(screen_name)
    print("name: " + item.name)
    print("screen name: " + item.screen name)
    print("description: " + item.description)
    print("friends count: " + str(item.friends count))
    print("followers_count: " + str(item.followers count))
    resultado = api.user_timeline(id=screen_name, count=tweetCount)
    for tweet in resultado:
        print(tweet.text)
get_last_tweets_x_user("@realDonaldTrump")
```

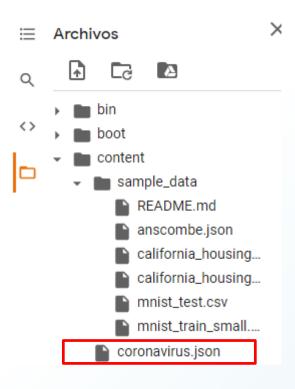
Obtener información de un Usuario

```
Getting data for @realDonaldTrump
name: Donald J. Trump
screen name: realDonaldTrump
description: 45th President of the United States of AmericaUS
friends count: 46
followers count: 79804712
THANK YOU, WORKING HARD! #MAGA https://t.co/NytV20gopi
As I have said for a long time, dealing with China is a very expensive thing to do. We just
made a great Trade Deal... https://t.co/aVzJ0Lr10S
When the so-called "rich guys" speak negatively about the market, you must always remember
that some are betting bi... https://t.co/d2GPNzjaAU
RT @dcexaminer: "It was the worst journalistic fiasco of now my more than 50 some years in
journalism."
@BritHume called the media's cover...
RT @dcexaminer: MORE:
https://t.co/34C4HQoyNG
RT @alexsalvinews: Fox News' Brit Hume calls the media's coverage of alleged collusion with
the Trump campaign and Russia the "worst journa...
RT @dbongino: Brit Hume: Mueller report coverage 'worst journalistic fiasco' he's seen in
50-year news caree https://t.co/bYiMt30Kar
Obama was always wrong! https://t.co/xRU4kJtExs
Does anybody believe this man? Caught! https://t.co/WfnIqs6BsE
"Newly released documents show Schiff knew all along there was no proof of Russia-Trump
collusion." Wall Street Journal
```

Obtener tweets en Tiempo Real

```
""" Obtener tweets en linea"""
                                                  StreamListener: Establece una sesión streaming
class MyListener(StreamListener):
    def on data(self,data):
        print("")
        try:
                                                                    Nombre del archivo donde
            with open("vizcarra13052020.json", "a") as f:
                                                                    se grabarán los tweets
                f.write(data)
                return True
        except BaseException as e:
            print(e)
            return True
    def on error(self, status):
        print(status)
        return True
auth = tweepy.OAuthHandler(consumer key, consumer secret)
auth.set access token(access key, access secret)
twitter stream = Stream(auth, MyListener())
                                                           Invocación de la clase streaming
twitter_stream.filter(track=["vizcarra"], languages=['es'] ) ------> Palabra clave y lenguaje
```

Obtener tweets en Tiempo Real



Obtener tweets en Tiempo Real

```
created at:
                                              "Wed May 13 17:36:16 +0000 2020"
  id:
                                               1260624918930010000
  id str:
                                               "1260624918930010112"
                                               "Aló Vizcarra"
  text:
                                              "<a href=\"http://twitter.com/downLoad/android\" rel=\"nofollow\">Twitter for Android</a>"

▼ source:
  truncated:
                                              false
  in_reply_to_status_id:
                                              nul1
  in_reply_to_status_id_str:
                                              nu11
  in reply to user id:
                                              nul1
  in_reply_to_user_id_str:
                                              nu11
  in_reply_to_screen_name:
                                              nul1
user:
                                              {_}}
  geo:
                                              nul1
                                              nu11
  coordinates:
  place:
                                              nul1
  contributors:
                                              null
  quoted_status_id:
                                              1260622663761956900
  quoted status id str:
                                               "1260622663761956866"
▼ quoted_status:
    created at:
                                               "Wed May 13 17:27:18 +0000 2020"
    id:
                                               1260622663761956900
    id str:
                                               "1260622663761956866"
                                              "Bravooo!!! #MinasBuenaventura dona planta de generación de oxígeno a hospital de Iquitos, la empresa privada se sig_ https://t.co/qJwiGθu3ud"
  display text range:
                                              \Gamma_{-1}
   source:
                                              "<a href=\"https://mobile...ow\">Twitter Web App</a>"
```

Obtener tweets con fecha

```
def obtener tweets(screen name):
    search words = screen name
   date since = "2020-08-14"
   new search = search words + " -filter:retweets"
   api = autenticacion()
   outtweets = []
                                                    Cursor: Función para manejar la paginación
   for tweet in tweepy.Cursor(api.search,
                                                    api.search: la función del api para la búsqueda
              q=new search.
                                                    q=new_search: cadena a buscar
              lang="es",
                                                    lang: idioma (ejemplo: "es" para español
              since=date since).items(100):
                                                    since: fecha desde donde se extraerán los tweets
      full text = tweet.text
      print(full text)
      outtweets.append((tweet.id_str, tweet.created_at, strip_undesired_chars(full_text),
                        tweet.retweet count,str(tweet.favorite count)+''))
   with open('%s search.csv' % screen name, "w", encoding="utf-8", newline='') as f:
                                                                                              Función para
        writer = csv.writer(f, quoting=csv.QUOTE ALL)
                                                                                              guardar los datos
        writer.writerow(['id','created at','text','retweet count','favorite count'''])
                                                                                              en archivo csv
        writer.writerows(outtweets)
    pass
```

Leer tweets de archivos csv

```
import pandas as pd

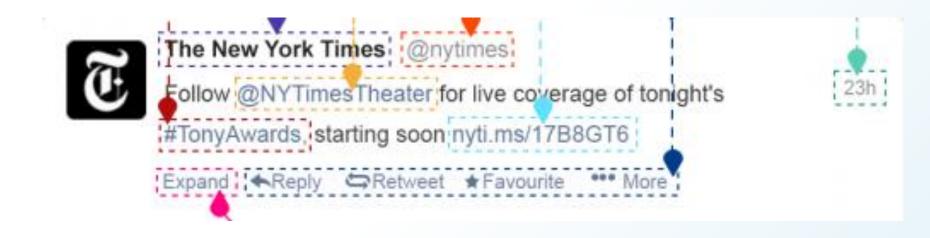
def leer_tweets(name):
    data = pd.read_csv(name, encoding = "UTF-8")
    tweets = data['text']
    for t in tweets:
        print(t)

leer_tweets('#pzifer_search.csv')
```

DataFrame

	apples	oranges
0	3	0
1	2	3
2	0	7
3	1	2

Tokenizar tweets



Tokenizar tweets

RT @amla: sólo un ejemplo! :D http://example.com #NLP en Perú :-)





['RT', '@', 'amla', ':', 'sólo', 'un', 'ejemplo', '!', ':', 'D', 'http', ':', '//example.com', '#', 'NLP', 'en', 'Perú', ':', '-', ')']

Tokenización normal

['RT', '@amla', ':', 'sólo', 'un', 'ejemplo', '!', ':D', 'http://example.com', '#NLP', 'en', 'Perú', ':-)']

Tokenización de tweet

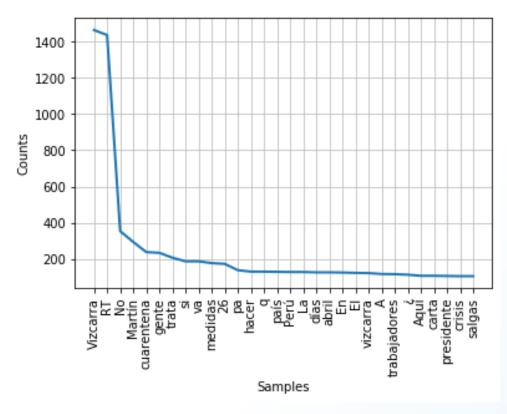
Tokenizar tweets

```
""" tokenizar tweets"""
def preprocess(s):
    emoticons str = r"""
    (?:
        [:=;] # Eyes
        [oO\-]? # Nose (optional)
       [D\)\]\(\]/\\OpP] # Mouth
    regex str =[emoticons str,
                r'<[^>]+>' , #HTML tags
                r'(?:@[\w_]+)', #@-Mención
                r"(?:\#+[\w_]+[\w\'_\-]*[\w_]+)" , #Hash-tags
                r'http[s]?://(?:[a-z]|[0-9]|[$-_@.&+]|[!*\(\),]|(?:%[0-9a-f])[0-9a-f]))+', #URLs
                r'(?:[\w_]+)' , #Otras Palabras
                r'(?:\S)' #Otras Palabras
   tokens_re = re.compile (r'('+'|'.join(regex_str)+')' ,re.VERBOSE | re.IGNORECASE)
   tokens = tokens re.findall(s)
    return tokens
tweet = ' RT @amla: sólo un ejemplo! :D http://example.com #NLP en Perú :-)'
print(word_tokenize(tweet))
print(preprocess(tweet))
```

Estadísticas de tweets

```
def leer tweets(name):
    data = pd.read csv(name, encoding = "UTF-8")
    print(data)
   tweets = data['text']
   tweets tokens all=[]
   for t in tweets:
       print(t)
       terms all = [term for term in preprocess(t)
                            if term not in stopwords]
       tweets tokens all.extend(terms all)
    terms hash = [term for term in tweets tokens all if term.startswith('#')]
    fdist = nltk.FreqDist(terms hash)
    print('50 palabras mas frequentes',fdist.most common(50))
   fdist.plot(30, cumulative=False)
    terms only = [term for term in tweets tokens all if term not in stopwords
                   and not term.startswith(('#', '@'))]
    fdist todos = nltk.FreqDist(terms only)
    print('50 palabras mas frequentes',fdist todos.most common(50))
    fdist todos.plot(30, cumulative=False)
leer tweets('#pzifer search.csv')
```

Estadísticas de tweets



```
Distribución de Frequencia de Todas las Palabras
50 palabras mas frequentes [('Vizcarra', 1465), ('RT', 1437), ('No', 353), ('Martín', 293), ('cuarentena', 237), ('gente', 233), ('trata', 206), ('si', 186), ('va', 186), ('medidas', 176), ('26', 172), ('pa', 137), ('hacer', 129), ('q', 129), ('país', 128), ('Perú', 127), ('La', 127), ('días', 125), ('abril', 125), ('En', 124), ('El', 122), ('vizcarra', 121), ('A', 116), ('trabajadores', 115), ('¿', 112), ('Aquí', 106), ('carta', 106), ('presidente', 105), ('crisis', 104), ('salgas', 104), ('masivos', 103), ('conchatumare', 103), ('Ministro', 103), ('plena', 102), ('despidos', 102), ('Salud', 102), ('ministra', 100), ('laborales', 100), ('Una', 100), ('empresas', 100), ('Presidente', 99), ('solo', 99), ('solicitado', 98), ('aplicar', 98), ('paquete', 98), ('puedan', 98), ('https://t.co/uHomt1wfdy', 98), ('haciendo', 98), ('Lima', 97), ('ver', 92)]
```

Taller de Análisis Semántico en la SEPLN

tweet ID

user ID

content

creation date

language (always 'es'

global polarity, in 5 levels:

P+, P, NEU, N, N+ plus NONE

agreement level: AGR, DISAGR

when applicable, polarity and agreement level related to each entity topics₀

```
<tweet>

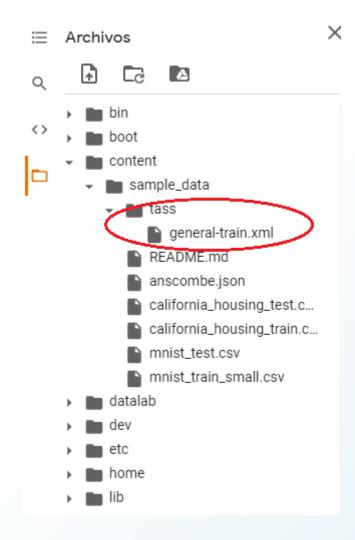
    <tweetid>0000000000</tweetid>

<user>usuario0</user>
   <content>
      <![CDATA['Conozco a alguien q es adicto al drama! Ja ja ja te suena d algo!]]>
   </content>
<lang>es</lang>
   <sentiments>
      <polarity>
         <value>P+</value>
         <type>AGREEMENT</type>
      </polarity>
   </sentiments>
   <topics>
      <topic>entretenimiento </topic>
   </topics>
</tweet>
<tweet>
   <tweetid>000000001</tweetid>
   <user>usuario1</user>
   <content>
      <![CDATA['UPyD contará casi seguro con grupo gracias al Foro Asturias.]]>
   </content>
   <date>2011-12-02T00:21:01</date>
   <lang>es</lang>
    sentiments>
      <polarity>
         <value>P</value>
         <type>AGREEMENT</type>
      </polarity>
      <polarity>
          <entity>UPyD</entity>
         <value>P</value>
         <type>AGREEMENT</type>
      </polarity>
         <entity>Foro_Asturias</entity>
         <value>P</value>
         <type>AGREEMENT</type>
      </polarity>
   </sentiments>

    <topics>

  <topic>política</topic>
   </topics>
</tweet>
```





Extraer datos de TASS

```
stopwords = nltk.corpus.stopwords.words('spanish')

def bag_of_words(words):
    words_dictionary = dict([word, True] for word in words)
    #print('dictionario',words_dictionary)
    return words_dictionary
```

```
def obtain_tokens(tweet):
    tweet_token = [term for term in preprocess(tweet) if term not in stopwords]
```

Leer archivos TASS

```
for fileName in listFiles:
      soup = BeautifulSoup(open(fileName,'r',encoding='utf8'),features="xml")
     for tweet in soup.find all("tweet"):
         words = obtain_tokens(tweet.content.text)
         label = tweet.sentiments.polarity.value.text
         if (label=='NONE'):
             #etiqueta='X'
             continue
         if (label=='NEU'):
             etiqueta='Y'
         if (label in ('N', 'P')):
             etiqueta=label
                                                 for words in pos reviews:
             if (label=='N'):
                                                       pos_reviews_set.append((bag_of_words(words), 'pos'))
                  neg reviews.append(words)
                                                 for words in neg reviews:
                  count1= count1+1
                                                       neg reviews set.append((bag of words(words), 'neg'))
             if (label=='P'):
                  pos reviews.append(words)
                                                 size = int(len(pos_reviews_set) * 0.1)
                 count2= count2+1
                                                 testSet = pos_reviews_set[:size] + neg_reviews_set[:size]
         count= count+1
                                                 trainSet = pos reviews set[size:] + neg reviews set[size:]
```

Ejecutar clasificador

```
def clasificadorSentimientos(loc):
    (trainSet, testSet) = lee datos(loc)
    #Naive Bayes classifier
    classifier1 = nltk.NaiveBayesClassifier.train(trainSet)
    print('Naive Bayes classifier',nltk.classify.accuracy(classifier1, testSet))
    #Predicting on the test set.
    X test = [f for (f,pos) in testSet]
    v test = [pos for (f,pos) in testSet]
    predSet=[]
    for xtest in X test:
      v pred = classifier1.classifv(xtest)
      predSet.append(v pred)
    f1 score2 = flat f1 score(y test, predSet, average = 'weighted')
    print('f1 score',f1 score2)
    report = flat classification report(y test, predSet)
    print(report)
    return classifier1
locCorpusTass1 = '/content/sample data/tass/'
clasificadorSentimientos(locCorpusTass1)
```

Ejecutar clasificador

Naive Bayes classifier 0.6829268292682927 f1_score 0.6781400966183575

11_300/0 010/	precision		f1-score	support
N	0.65	0.80	0.72	123
P	0.74	0.56	0.64	123
accuracy macro avg weighted avg	0.69 0.69	0.68 0.68	0.68 0.68 0.68	246 246 246

Predicciones

```
tweet1="@dw_espanol: Lo más triste de la #pandemia del #coronavirus son la cantidad de fallecidos"
tweet2="@dw_espanol: Todos los adultos mayores al fin vacunados!!!"
print(tweet1, clas.classify(bag_of_words(obtain_tokens(tweet1))) )
print(tweet2, clas.classify(bag_of_words(obtain_tokens(tweet2))) )
```

```
@dw_espanol: Lo más triste de la #pandemia del #coronavirus son la cantidad de fallecidos N @dw_espanol: Todos los adultos mayores al fin vacunados!!!P
```

Gracias!

Alguna pregunta?

Maria.limaylla@gmail.com